

Modélisation du Bonheur Mondial par Apprentissage Automatique

Noé Arokeum

Contents

1 Introduction	2
2 DataSet	3
2.1 Choix du DataSet	3
2.2 Justification du Choix des Variables	3
2.2.1 Consolidation des critères classiques du bonheur	3
2.2.2 Les limites du modèle classique	4
2.2.3 Nouvelles variables pour expliquer le « Résidu »	4
2.3 Analyse Exploratoire des Variables	5
2.4 Matrice de Corrélation et Sélection des Variables	8
3 Apprentissage Supervisé — Régression	10
3.1 Régression Linéaire	10
3.2 Random Forest	11
3.3 Gradient Boosting	12
3.4 Synthèse des résultats de régression	12
4 Classification	14
4.1 Construction des classes de bonheur	14
4.2 Résultats avec qcut (classes équilibrées)	14
4.3 Résultats avec cut (seuils fixes)	15
4.4 Bilan de la classification	15
5 Apprentissage Non Supervisé — K-Means	17
5.1 Choix du nombre de clusters	17
5.2 Visualisation des clusters (projection ACP)	17
5.3 Profils moyens par cluster	18
5.4 Cas d'étude : Nicaragua vs Corée du Sud	19
5.5 Validation du clustering par le rang de bonheur	19
6 Analyse Comparative — 2015 vs 2018	21
6.1 Stabilité des corrélations	21
6.2 Performances en régression	22
6.3 Performances en classification	23
6.4 Clustering : des profils stables dans le temps	23
6.5 Synthèse de l'analyse comparative	25
7 Conclusion Générale	26

1. Introduction

Le bonheur est une notion complexe, subjective et multidimensionnelle. Pourtant, depuis 2012, le *World Happiness Report* tente de le quantifier à l'échelle mondiale en attribuant à chaque pays un score issu de l'Échelle de Cantril, où les individus évaluent leur vie sur une échelle de 0 à 10. Ce score, appelé **Life Evaluation**, constitue notre variable cible.

Le rapport officiel décompose traditionnellement ce score en six facteurs explicatifs (PIB par habitant, soutien social, espérance de vie, liberté, générosité et perception de la corruption). Cependant, une part significative du score reste classée dans la catégorie « Dystopia + Residual », c'est-à-dire la part inexpliquée par le modèle. À titre d'exemple, cette part représente environ un tiers du score pour le Costa Rica et près de la moitié pour le Bénin.

Ce constat constitue le point de départ de notre projet : **peut-on mieux expliquer le bonheur déclaré des pays en mobilisant des indicateurs objectifs et diversifiés, au-delà des dimensions classiques du WHR ?**

Notre démarche s'articule en deux temps. Dans un premier temps, nous avons repris les grandes catégories classiques (Economie, Santé, Liberté, Gouvernance) en les mesurant avec des données plus robustes et tangibles. Dans un second temps, face à la part inexpliquée de ces modèles, nous avons élargi notre spectre à de nouveaux indicateurs (taux de suicide, pollution, accès à la mer, solde migratoire, inégalités de genre, utilisation d'Internet) susceptibles de capter des dimensions psychologiques, environnementales et sociales du bien-être.

Le dataset final porte sur **156 pays** pour l'année **2018** et regroupe **12 datasets** de sources variées (World Bank, UNDP, Freedom House, Our World in Data, Kaggle). Ce rapport présente successivement la description des variables retenues, l'analyse exploratoire, les transformations appliquées, puis les modèles de régression, classification et clustering mis en œuvre.

2. Dataset et Description des Variables

2.1 Choix du Dataset

La source principale de notre projet est le fichier **WHR25 Data Figure 2.1v3 BONHEUR.csv**, issu du World Happiness Report 2025. Il contient 13 colonnes dont les colonnes cibles « country », « year » et « Life Evaluation ».

La variable **Life Evaluation** mesure le niveau de bonheur à partir d'une enquête internationale. Elle correspond à la moyenne des réponses données par les individus à une question unique, appelée l'Échelle de Cantril, où chacun évalue sa vie sur une échelle de 0 à 10. Le score d'un pays est obtenu en calculant la moyenne des réponses sur les trois dernières années. Les autres variables du dataset (PIB par habitant, soutien social, espérance de vie, liberté, générosité et perception de la corruption) n'interviennent pas dans le calcul de ce score. Elles sont utilisées pour analyser et expliquer les différences de perception du bonheur entre les pays.

2.2 Justification du Choix des Variables

Pour construire notre modèle d'estimation du niveau de bonheur, notre démarche s'est articulée en deux étapes. Nous nous sommes d'abord appuyés sur les dimensions fondamentales du World Happiness Report, en cherchant à les mesurer avec des données plus robustes. Ensuite, face à la part inexpliquée de ces modèles classiques, nous avons élargi notre spectre à de nouveaux indicateurs.

2.2.1 Consolidation des critères classiques du bonheur

Dans un premier temps, nous avons repris les grandes catégories qui expliquent traditionnellement le score de bonheur (Economie, Santé, Liberté, Gouvernance), mais en sélectionnant des indicateurs objectifs et tangibles :

- **Le niveau de vie (PIB par habitant)** : Nous avons conservé cette variable incontournable qui mesure la capacité d'un pays à répondre aux besoins matériels de base. (Source : World Bank Group)
- **La santé et l'éducation (IDH et Accès à l'eau)** : Pour aller plus loin que la simple espérance de vie, nous avons intégré l'Indice de Développement Humain (qui inclut la scolarisation) ainsi que le taux d'accès à l'eau potable. Ce dernier est un indicateur direct de la qualité des infrastructures vitales et de la santé publique.
- **La liberté (Indice Freedom House)** : Plutôt que de s'appuyer sur un sentiment subjectif de liberté, nous avons utilisé les données de Freedom House. Cela permet de mesurer la liberté sous l'angle réel des droits politiques et des libertés civiles. (Source : Freedom House)
- **La gouvernance (Instabilité politique et Guerres)** : Pour remplacer la simple « perception de la corruption », nous avons intégré des données sur l'instabilité politique et les conflits. La sécurité physique et institutionnelle est un pilier fondamental (pyramide de Maslow) sans lequel le bonheur est impossible. (Sources : World Bank Group pour l'instabilité politique, Our World in Data pour les guerres)

2.2.2 Les limites du modèle classique

Malgré la pertinence de ces premiers critères, l'analyse des données montre qu'ils ne suffisent pas à expliquer l'intégralité du bonheur perçu. Dans les données officielles, une grande partie du score des pays est d'ailleurs classée dans la catégorie « Dystopia + Residual » (la part inexpliquée par le modèle). À titre d'exemple, cette part inexpliquée représente environ un tiers du score total pour un pays comme le Costa Rica, et près de la moitié du score pour le Bénin. Ce constat nous a menés à une conclusion claire : d'autres facteurs, invisibles, influencent profondément le bien-être des habitants. Nous avons donc décidé d'introduire de nouvelles variables pour tenter de « décoder » ce résidu.

2.2.3 Nouvelles variables pour expliquer le « Résidu »

Pour capter ces dimensions cachées (psychologiques, environnementales et sociales), nous avons ajouté les indicateurs suivants :

- **Taux de suicide** : Cet indicateur permet de capter la détresse profonde et la solitude que le PIB ou l'IDH ne montre pas. Exemple du Japon : malgré un PIB élevé et une grande sécurité, ce pays illustre comment une pression sociale et scolaire intense peut dégrader le bien-être mental, un facteur souvent invisible dans les statistiques économiques classiques. (Source : Our World in Data)
- **Accès à la mer** : L'enclavement est souvent un frein au développement. L'accès à la mer facilite les échanges commerciaux, l'accès à des ressources alimentaires diversifiées et possède une dimension psychologique reconnue pour réduire le stress des populations côtières. (Source : Kaggle)
- **Pollution de l'air (Particules fines PM2.5)** : La qualité de l'environnement est un facteur de santé publique majeur. Un air pollué est lié à des troubles de l'humeur et à une baisse de la qualité de vie urbaine. C'est aussi un indicateur de la responsabilité écologique du gouvernement. (Source : World Bank Group)
- **Le solde migratoire net (Immigration/Émigration)** : C'est la traduction comportementale du bonheur. Un pays attractif (solde positif) est perçu comme une terre d'opportunités, tandis qu'un solde négatif traduit une fuite face à un manque de perspectives ou de bien-être. (Source : World Bank Group)
- **Inégalités de genre et sociales (IIG)** : Le bonheur est corrélé à la cohésion sociale. Un pays où les écarts de richesse sont abyssaux ou où une partie de la population (les femmes) subit des discriminations structurelles génère de la frustration et un sentiment d'injustice globale. (Source : Human Development Report)
- **Taux d'utilisation d'Internet** : À l'ère numérique, l'accès à Internet est synonyme d'ouverture sur le monde, d'accès à l'information et de maintien du lien social. C'est un outil indispensable pour l'autonomie individuelle dans les sociétés modernes.

2.3 Analyse Exploratoire des Variables

Une fois les 11 variables candidates réunies autour de la cible **Life Evaluation**, nous avons procédé à une analyse exploratoire systématique pour vérifier la qualité des données, détecter les asymétries et les valeurs extrêmes, et déterminer les transformations nécessaires avant la modélisation.

2.3.1 Distribution des variables

La visualisation ci-dessous présente la distribution de chacune des 11 variables explicatives sur les 156 pays du dataset. Plusieurs observations ressortent immédiatement :




Figure 1 — Distribution des 11 variables explicatives avant transformations.

On constate que **GDP_per_capita** et **PM25** présentent des distributions très asymétriques (forte concentration à gauche avec une longue queue à droite). Pour **GDP_per_capita**, la grande majorité des pays se concentre sous 20 000 \$ avec quelques pays très riches dépassant les 100 000 \$. Pour **PM25**, la plupart des pays ont des concentrations entre 10 et 30 $\mu\text{g}/\text{m}^3$, mais quelques pays très pollués atteignent 80 $\mu\text{g}/\text{m}^3$. Ces distributions fortement étirées posent problème pour les modèles linéaires qui supposent une relation proportionnelle entre les variables.

2.3.2 Transformations logarithmiques

Pour corriger ces asymétries, nous avons appliqué une **transformation logarithmique** à **GDP_per_capita** et à **PM25**. L'objectif est d'obtenir des distributions plus proches d'une gaussienne, ce qui améliore le comportement des modèles de régression et réduit l'influence disproportionnée des valeurs extrêmes. Les figures ci-dessous montrent l'effet de la transformation :

PM25 — Avant et après la transformation log




Figure 2a — PM25 brut (asymétrie à droite)




Figure 2b — $\log(\text{PM25})$ (distribution normalisée)

GDP_per_capita — Avant et après la transformation log




Figure 3a — GDP brut (forte concentration à gauche)




Figure 3b — $\log(\text{GDP})$ (distribution plus équilibrée)

Après transformation, les deux variables présentent des distributions nettement plus symétriques et étalées. Pour PM25, la distribution passe d'une queue lourde à droite à une forme quasi-gaussienne centrée autour de 3.0. Pour GDP_per_capita, la transformation élimine l'écrasement des pays à faible revenu et donne une distribution bien répartie entre 6 et 12 (en échelle log).

Note : Le taux de suicide (*Suicide_Rate*) est conservé tel quel car les tests montrent que la transformation $\log$ n'améliore pas le score global du modèle.

2.3.3 Recodage de Coastline

La variable **Coastline** brute a une corrélation quasi nulle avec *Life Evaluation* ($r \approx 0.05$). Pourtant, l'accès à la mer peut contribuer au bonheur. Le problème vient de valeurs très hétérogènes : par exemple, les Maldives affichent un ratio *Coastline* de 214, tandis que les États-Unis sont à 0.21. Une valeur aussi extrême que celle des Maldives pourrait poser problème en faussant les modèles et en tirant les coefficients vers des valeurs non représentatives.

Nous avons donc reclassé cette variable en catégories à **seuils fixes** :

Catégorie	Définition
0	Pas d'accès à la mer (pays enclavé)
1	Accès modéré ($\text{Coastline} \leq \text{médiane} = 0.56$)
2	Accès élevé ($\text{Coastline} > \text{médiane} = 0.56$)

La médiane des pays côtiers ($\text{Coastline} > 0$) est de **0.56**. On utilise *pd.cut* avec des seuils fixes plutôt que *pd.qcut* pour éviter tout *data leakage* (les quantiles calculés sur tout le dataset fuiraient de l'information du test vers le train).

Après recodage, la moyenne de *Life Evaluation* par catégorie révèle une tendance claire :

Coastline (catégorie)	Moyenne de Life Evaluation
0 — Pas d'accès	4.942
1 — Accès modéré	5.164
2 — Accès élevé	5.979

On observe qu'en général, **plus le Life Evaluation est bas, plus la Coastline moyenne est basse**. Les pays enclavés (catégorie 0) affichent un score moyen de 4.94, tandis que les pays à accès élevé à la mer atteignent 5.98. Ce gradient confirme l'intérêt de conserver cette variable sous forme recodifiée.

2.3.4 Traitement des valeurs manquantes

Avec seulement 156 pays, supprimer des lignes contenant des valeurs manquantes serait coûteux. Nous avons donc utilisé **KNNImputer** (k=5) pour estimer les valeurs manquantes à partir des voisins les plus proches. L'imputation est appliquée **après** la séparation train/test pour éviter tout *data leakage*.

2.4 Matrice de Corrélation et Sélection des Variables

Avant de passer à la modélisation, il est essentiel de vérifier si les variables candidates sont réellement utiles (corrélation avec la cible) et s'il n'existe pas de liens trop forts entre elles (multicolinéarité). La matrice de corrélation de Pearson ci-dessous résume ces relations :




Figure 4 — Matrice de corrélation de Pearson entre les 12 variables (cible incluse).

2.4.1 Corrélations avec la variable cible

Les corrélations les plus fortes avec **Life Evaluation** sont : **GDP_per_capita** ($r = 0.84$), **HDI** ($r = 0.81$), **population using the Internet** ($r = 0.79$), **Water_Access** ($r = 0.68$), et **Freedom_Score** ($r = 0.59$). En sens inverse, **GII** ($r = -0.77$) et **PM25** ($r = -0.56$) sont négativement corrélées au bonheur : plus les inégalités de genre et la pollution sont élevées, plus le score de bonheur est faible.

2.4.2 Analyse de la multicolinéarité

La matrice révèle des corrélations très élevées entre plusieurs indicateurs de développement :

- **population using the Internet** : très corrélée avec GDP_per_capita ($r = 0.92$), HDI ($r = 0.94$), GII ($r = -0.88$) et Water_Access ($r = 0.84$). Bien que fortement liée à Life Evaluation ($r \approx 0.79$), elle est redondante avec les autres.
- **HDI** : corrélé à 0.95 avec GDP_per_capita, à -0.92 avec GII et à 0.86 avec Water_Access.
- **GII et Water_Access** : corrélées avec GDP_per_capita à des niveaux élevés ($|r| > 0.79$).

L'exclusion de **HDI**, **GII**, **population using the Internet** et **Water_Access** repose sur le problème statistique de la **multicolinéarité**. Intégrer des variables « doublons » dans une régression linéaire

n'apporte pas d'information nouvelle mais augmente artificiellement la variance des coefficients estimés. Cela rend les coefficients instables et difficilement interprétables.

2.4.3 Variables retenues pour la régression

Au terme de cette analyse, les **7 variables** retenues pour la régression linéaire sont :

Variable	Corrélation avec Life Evaluation	Justification
GDP_per_capita (log)	0.84	Proxy du développement économique
Freedom_Score	0.59	Libertés civiles et droits politiques
PM25 (log)	−0.56	Qualité environnementale
Coastline (recodifié)	0.38	Accès à la mer (après recodage)
Conflit	−0.30	Stabilité politique et sécurité
Suicide_Rate	0.26	Santé mentale et détresse sociale
Net_Migration	0.18	Attractivité du pays

Pour les modèles non linéaires (Random Forest, Gradient Boosting), la multicolinéarité ne biaise pas les prédictions. Nous pourrions donc réintroduire les 11 variables dans ces modèles pour comparer les résultats.

3. Apprentissage Supervisé — Régression

Cette section explore trois familles de modèles de régression pour prédire la variable continue *Life Evaluation* : la régression linéaire, le Random Forest et le Gradient Boosting. Pour chaque famille, nous comparons plusieurs configurations de variables afin d'évaluer l'impact du choix des prédicteurs sur la performance et l'interprétabilité du modèle.

Le protocole expérimental est identique pour tous les modèles : séparation train/test (80/20, random_state=42), imputation des valeurs manquantes par KNNImputer (k=5) ajusté **uniquement sur le train**, et standardisation par StandardScaler.

3.1 Régression Linéaire

3.1.1 Modèle PIB (7 variables)

Le premier modèle de régression linéaire utilise les 7 variables retenues après l'analyse de multicollinéarité, avec **GDP_per_capita (log)** comme proxy du développement économique. Les résultats obtenus sont : R^2 Train = 0.661, R^2 Cross-validation (5-fold) = 0.571, R^2 Test = 0.786, MSE Test = 0.289.




Figure 5 — Coefficients standardisés de la régression linéaire (modèle PIB).

L'analyse des coefficients révèle que **GDP_per_capita** écrase toutes les autres variables avec un coefficient très élevé (~0.76). Freedom_Score arrive en seconde position (~0.17), tandis que les autres variables ont des poids marginaux. Coastline affiche un impact négatif inattendu et Suicide_Rate a une importance étonnamment faible. Ce résultat confirme un lien connu entre PIB et bonheur mais sans révéler la contribution des autres dimensions.

3.1.2 Modèle Internet (7 variables)

Nous substituons GDP_per_capita par **population using the Internet**. Cette variable présente une distribution mieux équilibrée et capture non seulement la richesse, mais aussi l'infrastructure, l'éducation et l'ouverture sociale d'un pays. La matrice de corrélation montre que HDI, GII et Water_Access sont corrélées à plus de 85 % avec l'accès à Internet — parfois davantage qu'avec le PIB. Résultats : R^2 Train = 0.662, R^2 CV = 0.573, R^2 Test = 0.755, MSE Test = 0.329.




Figure 6 — Coefficients standardisés de la régression linéaire (modèle Internet).

Dans ce modèle, bien que la performance globale baisse légèrement, le poids de la variable principale est moins dominant. Cela laisse de la place aux autres facteurs : le **Freedom_Score** voit son influence augmenter sensiblement (~ 0.27) et l'impact négatif de la pollution (**PM25**) devient plus visible (~ -0.18). Le modèle Internet est statistiquement un peu moins précis, mais **sociologiquement plus riche** : il montre que l'accès à l'information est un excellent indicateur du développement qui met en lumière l'importance de la liberté individuelle et de l'environnement dans le score de bonheur.

3.2 Random Forest

Le Random Forest gère naturellement les relations non linéaires et les interactions entre variables. Contrairement à la régression linéaire, la multicollinéarité ne biaise pas les prédictions (bien que les *feature importances* puissent se répartir entre variables corrélées). On peut donc réintroduire les 11 variables. Paramètres : `n_estimators=200`, `max_depth=5`, `min_samples_leaf=5`, `max_features='sqrt'`.

Trois configurations sont testées : 11 variables (toutes), 7 variables avec PIB, et 7 variables avec Internet.




Figure 7 — Importance des variables (Gini) — Random Forest à 11 variables.




Figure 8 — RF 7 vars (PIB)




Figure 9 — RF 7 vars (Internet)

Dans les deux configurations à 7 variables, le Random Forest donne beaucoup plus d'importance aux variables « secondaires » que la régression linéaire. La pollution (**PM25**) et la liberté (**Freedom_Score**) pèsent chacune entre 17 % et 23 % dans la décision du modèle. La supériorité du PIB dans tous les modèles confirme que le développement économique reste le socle du bonheur mesuré. Cependant, le fait que PM25 et Freedom_Score conservent une importance élevée quel que soit le modèle prouve que **le bonheur ne peut être réduit à une seule dimension économique**.

3.3 Gradient Boosting

Le Gradient Boosting (HistGradientBoostingRegressor) construit séquentiellement des arbres qui corrigent les erreurs des précédents. Paramètres : max_iter=200, learning_rate=0.01–0.05, max_depth=3, l2_regularization=0.1.




Figure 10 — GB 7 vars (PIB)




Figure 11 — GB 7 vars (Internet)

Le modèle à 7 variables (PIB) présente l'écart train/test le plus marqué (R^2 Train $\approx$ 0.871 vs R^2 Test $\approx$ 0.714), signe d'**overfitting** : le modèle a trop « mémorisé » les données d'entraînement. Le modèle à 11 variables est le plus stable (R^2 Train $\approx$ R^2 Test $\approx$ 0.77), ce qui est contre-intuitif : disposer de plus de variables permet au Gradient Boosting de mieux répartir l'information au lieu de tout miser sur une seule.

Contrairement au Random Forest (qui sous-échantillonne les variables à chaque split), le Gradient Boosting a tendance à se **focaliser sur la variable la plus prédictive** au détriment des autres — il a « misé tous ses jetons » sur le PIB. Le Random Forest reste globalement **plus robuste et plus équilibré** dans la répartition des importances.

3.4 Synthèse des résultats de régression

Modèle	Variables	R ² Train	R ² CV	R ² Test	MSE
Rég. Linéaire	PIB (7)	0.661	0.571	0.786	0.289
Rég. Linéaire	Internet (7)	0.662	0.573	0.755	0.329
Random Forest	11 variables	0.813	0.615	0.809	0.258

Random Forest	PIB (7)	0.750	0.554	0.742	0.347
Random Forest	Internet (7)	0.754	0.562	0.734	0.359
Gradient Boosting	11 variables	0.760	0.530	0.731	—
Gradient Boosting	PIB (7)	0.871	0.488	0.714	—
Gradient Boosting	Internet (7)	0.869	0.498	0.659	—

Tableau 1 — Récapitulatif des performances en régression.

Le **Random Forest à 11 variables** offre le meilleur compromis entre performance (R^2 Test = 0.809) et stabilité (faible écart train/test). La régression linéaire reste interprétable mais limite la contribution des variables secondaires. Le Gradient Boosting souffre d'overfitting lorsque le nombre de variables est restreint.

Les scores de validation croisée confirment cette hiérarchie : le Random Forest à 11 variables obtient le meilleur R^2 CV (0.615), tandis que le Gradient Boosting affiche les scores CV les plus bas (0.488-0.530), révélant un écart train/CV important qui traduit son overfitting. Ces scores CV, inférieurs aux R^2 Test, rappellent que sur un petit dataset de 156 pays, un seul split test peut surestimer la performance réelle.

4. Apprentissage Supervisé — Classification

4.1 Construction des classes de bonheur

Pour passer d'une prédiction continue à une catégorisation, nous avons classé les pays en trois niveaux de bonheur. Avant de choisir les seuils, nous avons observé la distribution de *Life Evaluation* :




Figure 12 — Distribution de Life Evaluation sur les 156 pays.

La distribution est assez étalée entre ~3 et ~7.8 avec une concentration entre 4.5 et 6.5, sans séparation nette. Prendre plus de 4 classes serait hasardeux ; 2 serait trop simpliste. Nous avons opté pour **3 classes** et testé deux approches :

- **pd.qcut** (classes équilibrées) : les frontières sont purement statistiques, chaque classe contient ~52 pays.
- **pd.cut** (seuils fixes [0, 4.5, 6.0, 10]) : les frontières ont une signification sociologique (« Malheureux », « Moyen », « Heureux »).

Pour les méthodes de classification, nous utilisons les **7 variables** (pas les 11), car des méthodes comme Naïve Bayes supposent l'indépendance conditionnelle des prédicteurs.

4.2 Résultats avec qcut (classes équilibrées)

Trois classifieurs sont entraînés : Régression Logistique, KNN (k=5) et Naïve Bayes Gaussien. Les résultats sont les suivants :

Modèle	Précision Train	Précision Test	Score CV	Classe « Moyen » bien classée
Régression Logistique	0.669	0.781	0.620	7 / 14
KNN (k=5)	0.694	0.688	0.499	5 / 14
Naïve Bayes	0.661	0.750	0.581	7 / 14

Tableau 2 — Performances des classifieurs avec qcut.




Figure 13 — Matrice de confusion — Régression Logistique (qcut).

Les classes extrêmes (« Malheureux » et « Heureux ») sont clairement identifiées par tous les modèles. C'est dans la zone « Moyen » que la classification devient difficile : sur les 14 pays de cette classe, au mieux 7 sont correctement classés par la Régression Logistique.

Le KNN fonctionne par proximité, ce qui suggère l'existence de **modèles régionaux de bonheur** : les pays partageant des structures similaires (pays nordiques, Amérique latine, Europe de l'Est) ont tendance à se regrouper. Cependant, ses performances restent les plus faibles en test (0.688).

Limite de qcut : les frontières sont purement statistiques. Un pays à 5.4 est classé « Moyen » et un pays à 5.6 est classé « Heureux » alors qu'ils sont objectivement très proches. Cette construction artificielle contribue aux erreurs sur la classe intermédiaire.

4.3 Résultats avec cut (seuils fixes)

En remplaçant qcut par **pd.cut(bins=[0, 4.5, 6.0, 10])**, les frontières prennent une signification sociologique : un pays sous 4.5 est considéré comme « Malheureux », entre 4.5 et 6.0 comme « Moyen », et au-dessus de 6.0 comme « Heureux ».

Modèle	Précision Train	Précision Test	F1 macro	Score CV	Classe « Moyen »
Régression Logistique	0.726	0.719	0.77	0.653	11 / 17
KNN (k=5)	0.734	0.650	0.71	0.556	11 / 17
Naïve Bayes	0.645	0.625	0.68	0.605	8 / 17

Tableau 3 — Performances des classifieurs avec cut (seuils fixes).

Le passage à des seuils fixes améliore la reconnaissance de la classe « Moyen » (11/17 contre 7/14 avec qcut), confirmant que certains pays « vraiment Moyens » étaient artificiellement poussés dans les classes extrêmes pour équilibrer les effectifs.

4.4 Bilan de la classification

Au-delà d'un certain seuil de développement, le bonheur devient multifactoriel et résiste à la modélisation quantitative. La majorité des erreurs se concentre sur la classe intermédiaire, ce qui suggère que des **facteurs qualitatifs ou culturels** non capturés par nos variables jouent un rôle déterminant. La Régression Logistique offre le meilleur compromis global.

Les scores de validation croisée confirment ces observations : la Régression Logistique obtient les meilleurs scores CV dans les deux configurations (0.620 avec qcut et 0.653 avec cut), ce qui témoigne d'une meilleure capacité de généralisation. Le KNN souffre davantage en validation croisée (0.499 et 0.556), signe d'une sensibilité au découpage des données et d'un possible surapprentissage. Les scores CV, systématiquement inférieurs aux précisions test, indiquent que les performances mesurées sur un seul split train/test sont légèrement optimistes, et que la validation croisée offre une estimation plus robuste et réaliste de la performance réelle des modèles.

5. Apprentissage Non Supervisé — K-Means

L'objectif du clustering est de vérifier si les variables socio-économiques choisies suffisent à faire émerger naturellement des groupes de pays cohérents avec le classement mondial du bonheur, **sans** utiliser Life Evaluation comme variable d'entrée.

5.1 Choix du nombre de clusters




Figure 14 — Méthode du coude et score de silhouette.

La méthode du coude suggère $k=2$ comme optimal, mais un découpage binaire serait peu informatif. Pour affiner le choix, nous avons utilisé un **dendrogramme** (classification hiérarchique avec la méthode de Ward) :




Figure 15 — Dendrogramme — Classification hiérarchique (Ward).

Le dendrogramme montre **3 branches principales** bien séparées avant la fusion finale. Nous retenons donc $k = 3$.

5.2 Visualisation des clusters (projection ACP)




Figure 16 — Projection ACP des clusters K-Means ($k=3$).

L'axe 1 (**PC1, 52.2 % de variance**) agit comme un indicateur de puissance socio-économique : il oppose les pays disposant d'un accès massif aux ressources (Internet, eau, PIB) aux pays marqués par des instabilités (conflits, inégalités). L'axe 2 (**PC2, 11.4 %**) apporte une nuance sur le contexte environnemental et social : il différencie les pays selon la pollution atmosphérique ou la santé mentale, facteurs qui ne dépendent pas uniquement du niveau de richesse.

5.3 Profils moyens par cluster




Figure 17 — Répartition du bonheur par cluster.

	Cluster 0 (61 pays)	Cluster 1 (50 pays)	Cluster 2 (45 pays)
--	---------------------	---------------------	---------------------

Life Evaluation	5.36	6.48	4.27
GDP_per_capita (log)	8.69	10.31	6.94
Freedom_Score	46.45	87.86	39.33
PM25 (log)	3.22	2.53	3.62
HDI	0.76	0.90	0.53
GII	0.34	0.13	0.57
Internet (%)	63.31	83.45	20.82
Suicide_Rate	6.69	13.19	6.98

Tableau 4 — Profils moyens par cluster.

- **Cluster 2 — Structurellement contraint** (45 pays) : scores de bonheur les plus bas (moyenne 4.27). Ces pays partagent un accès limité à l'eau et à Internet, des scores de liberté faibles et des inégalités de genre marquées. Exemples : Afghanistan, Burkina Faso, Cambodge, Tchad.
- **Cluster 0 — Intermédiaire / hybride** (61 pays) : le groupe le plus hétérogène (moyenne 5.36). Des pays aux profils très différents s'y côtoient, illustrant les limites du K-Means face à des profils complexes. Exemples : Algérie, Arménie, Botswana, Nicaragua.
- **Cluster 1 — Connecté et développé** (50 pays) : le groupe le plus homogène et le plus heureux (moyenne 6.48). Fort accès à Internet, IDH élevé, bonnes libertés individuelles. Exemples : Norvège, Espagne, Canada, Costa Rica.

5.4 Cas d'étude : Nicaragua vs Corée du Sud

	Costa Rica	Nicaragua	Corée du Sud
Cluster	1	0	1
Life Evaluation	7.167	6.105	5.895
GDP (log)	9.44	7.62	10.47
Freedom_Score	91	44	84
Suicide_Rate	7.53	5.27	28.28

Tableau 5 — Comparaison Nicaragua / Corée du Sud / Costa Rica.

La **Corée du Sud** (Cluster 1) dispose d'un PIB par habitant massif et d'un score de liberté élevé. Pourtant, son score de bonheur est de 5.895, **inférieur au Nicaragua** (Cluster 0, score de 6.105) qui a un PIB et une liberté bien plus faibles. Le taux de suicide illustre cette différence : 5.27 pour le Nicaragua contre 28.28 pour la Corée du Sud.

Cette comparaison démontre que **le PIB est un prédicteur de la richesse, pas nécessairement de la plénitude**. Des facteurs culturels et sociaux — santé mentale, soutien communautaire — que les statistiques macro-économiques ne capturent pas totalement jouent un rôle déterminant.

5.5 Validation du clustering par le rang de bonheur




Figure 18 — Score de bonheur par pays (triés), coloré par cluster K-Means.

Le K-Means, bien qu'il n'utilise pas *Life Evaluation* comme variable d'entrée, reproduit assez fidèlement le classement mondial de bonheur. C'est une **validation indirecte importante** : les variables socio-économiques choisies sont suffisamment représentatives pour que le clustering non supervisé retrouve spontanément l'ordre du bonheur.

Quelques barres isolées de couleur différente au milieu du graphique confirment les limites du K-Means sur les profils hybrides — notamment des pays comme la Chine, dont le profil économique fort mais le Freedom Score très bas crée une ambiguïté que l'algorithme ne résout pas parfaitement. On retrouve le même problème que pour la classification : nos algorithmes identifient bien les extrêmes mais peinent avec les **profils intermédiaires**.

6. Analyse Comparative — 2015 vs 2018

Les conclusions tirées dans les sections précédentes reposent exclusivement sur les données de l'année 2018. Pour vérifier si ces observations reflètent des **tendances structurelles du bonheur** plutôt que des particularités conjoncturelles, nous avons répliqué l'intégralité de notre pipeline (prétraitement, régression, classification, clustering) sur les données de **2015**, soit 157 pays avec les mêmes 11 variables. Cette section confronte les résultats des deux années.

6.1 Stabilité des corrélations




Figure 19 — Matrice de corrélation — 2015




Figure 20 — Matrice de corrélation — 2018

La comparaison des deux matrices de corrélation constitue le premier résultat marquant de cette analyse : **la structure des relations entre variables est remarquablement stable entre 2015 et 2018**. Les corrélations avec *Life Evaluation* restent dans le même ordre de grandeur :

Variable	r (2015)	r (2018)	Δ
GDP_per_capita (log)	0.85	0.84	-0.01
HDI	0.82	0.81	-0.01
Internet	0.79	0.79	0.00
GI	-0.73	-0.77	-0.04
Water_Access	0.70	0.68	-0.02
PM25 (log)	-0.61	-0.56	+0.05
Freedom_Score	0.53	0.59	+0.06
Coastline	0.35	0.38	+0.03
Conflit	-0.20	-0.30	-0.10
Suicide_Rate	0.28	0.26	-0.02
Net_Migration	0.25	0.18	-0.07

Tableau 6 — Corrélations avec Life Evaluation : 2015 vs 2018.

Les écarts sont minimes ($\Delta < 0.07$ pour la plupart). Seul **Conflit** voit sa corrélation négative se renforcer ($-0.20 \rightarrow -0.30$), ce qui pourrait refléter l'aggravation de certains conflits entre 2015 et 2018 (Syrie,

Yémen). Le léger renforcement de **Freedom_Score** (+0.06) suggère que la liberté individuelle a pris un poids légèrement plus important dans la perception du bonheur. La multicollinéarité entre HDI, GDP, Internet et GII est également présente en 2015, confirmant qu'il s'agit d'un trait structurel et non conjoncturel.

Le recodage de Coastline aboutit à des résultats quasi identiques : médiane de 0.54 en 2015 (vs 0.56 en 2018), et la même gradation du bonheur par catégorie (4.97 → 5.08 → 5.93).

6.2 Performances en régression

Modèle	Config.	R ² Test 2015	R ² Test 2018	Δ
Rég. Linéaire	PIB (7)	0.669	0.786	+0.117
Rég. Linéaire	Internet (7)	0.651	0.755	+0.104
Random Forest	11 vars	0.721	0.809	+0.088
Random Forest	PIB (7)	0.644	0.742	+0.098
Random Forest	Internet (7)	0.644	0.734	+0.090
Grad. Boosting	11 vars	0.671	0.731	+0.060
Grad. Boosting	PIB (7)	0.617	0.714	+0.097
Grad. Boosting	Internet (7)	0.625	0.659	+0.034

Tableau 7 — Comparaison des R² Test en régression (2015 vs 2018).

Première observation : **tous les modèles performant mieux sur 2018 que sur 2015**, avec un gain moyen de +0.08 en R² Test. Cela peut s'expliquer par une meilleure qualité des données en 2018 (moins de valeurs manquantes, sources plus complètes) ou par le fait que les structures socio-économiques se sont stabilisées, rendant les patterns plus prédictibles.

Deuxième observation : **la hiérarchie des modèles est identique**. Le Random Forest à 11 variables reste le meilleur modèle sur les deux années (0.721 en 2015, 0.809 en 2018). Le Gradient Boosting à 7 variables (PIB) souffre d'overfitting dans les deux cas (R² Train ≈ 0.88 vs R² Test ≈ 0.62–0.71).

Troisième observation : **le modèle Internet reste systématiquement légèrement en dessous du modèle PIB** en score brut, mais cette différence est faible et stable dans le temps. Cela renforce l'idée que l'accès à Internet est un **proxy légitime du développement** qui ne se dégrade pas avec les années.

6.2.1 Stabilité des coefficients de régression linéaire




Figure 21 — Coef. LR (PIB) — 2015




Figure 22 — Coef. LR (PIB) — 2018

Les graphiques de coefficients de la régression linéaire (modèle PIB) révèlent le même phénomène sur les deux années : **GDP_per_capita domine massivement** les autres variables, avec un coefficient standardisé autour de 0.75. Freedom_Score arrive en seconde position dans les deux cas.

L'écrasement par le PIB n'est donc pas un artefact de 2018 : c'est un **trait structurel** de la régression linéaire sur ce type de données.




Figure 23 — Coef. LR (Internet) — 2015




Figure 24 — Coef. LR (Internet) — 2018

De même, le modèle Internet montre une structure stable : Freedom_Score gagne en visibilité et PM25 conserve son impact négatif, confirmant l'intérêt sociologique de cette configuration sur les deux périodes.

6.3 Performances en classification

Modèle	Préc. Test 2015	Préc. Test 2018	Δ
Rég. Logistique (qcut)	0.656	0.781	+0.125
KNN (qcut)	0.625	0.688	+0.063
Naïve Bayes (qcut)	0.594	0.750	+0.156

Tableau 8 — Comparaison des précisions Test en classification (qcut).

La classification affiche le même constat que la régression : les modèles sont plus précis en 2018, mais la **hiérarchie est conservée**. La Régression Logistique reste le meilleur classifieur sur les deux années. Le Naïve Bayes progresse le plus (+0.156), suggérant que l'hypothèse d'indépendance conditionnelle est mieux respectée en 2018.

Fait remarquable : **la classe « Moyen » reste la plus difficile à classifier** sur les deux années. En 2015, la Régression Logistique ne classe correctement que 4 pays sur 8 de cette catégorie (50 %), contre 7/14 (50 %) en 2018. Cette difficulté persistante confirme que la zone intermédiaire du bonheur est intrinsèquement floue et ne dépend pas de l'année étudiée.

6.4 Clustering : des profils stables dans le temps

Le clustering K-Means (k=3) reproduit en 2015 les mêmes structures qu'en 2018. Le dendrogramme de 2015 confirme également 3 branches principales, validant le choix de k.





Figure 25 — Bonheur par cluster — 2015

Figure 26 — Bonheur par cluster — 2018

Les boxplots confirment visuellement la stabilité de la structure : trois groupes distincts avec le même profil (un groupe « contraint » en bas, un groupe « développé » en haut, un groupe « intermédiaire » au milieu). Les profils moyens sont les suivants :

	Contraint (2015)	Contraint (2018)	Développé (2015)	Développé (2018)
Nb pays	44	45	55	50
Life Eval.	4.14	4.27	6.32	6.48
GDP (log)	6.86*	6.94	10.06*	10.31
Freedom	34.48*	39.33	82.15*	87.86
Internet (%)	12.77	20.82	75.89	83.45
GII	0.55	0.57	0.14	0.13

Tableau 9 — Profils des clusters extrêmes (2015 vs 2018). *Valeurs 2015 légèrement inférieures en raison de la croissance économique.

Les évolutions entre 2015 et 2018 sont cohérentes avec le développement mondial : le taux d'utilisation d'Internet augmente dans tous les clusters (de 12.8 % à 20.8 % pour le cluster contraint, de 75.9 % à 83.5 % pour le cluster développé), les scores de liberté progressent légèrement, et le PIB augmente uniformément. Cependant, **la structure relative reste figée** : les écarts entre clusters ne se réduisent pas significativement.

6.4.1 Validation par le rang de bonheur




Figure 27 — Ranking coloré par cluster — 2015




Figure 28 — Ranking coloré par cluster — 2018

La comparaison des barplots est particulièrement parlante : **le K-Means retrouve spontanément l'ordre du bonheur** aussi bien en 2015 qu'en 2018, sans jamais utiliser *Life Evaluation* comme variable d'entrée. La même signature visuelle apparaît : un dégradé bleu → rouge → vert de gauche à droite, avec quelques barres isolées au milieu. Cette réplique à trois ans d'intervalle est une **validation forte** de la pertinence de nos indicateurs.

6.4.2 Le cas Nicaragua vs Corée du Sud : confirmé en 2015

	Nicaragua 2015	Nicaragua 2018	Corée 2015	Corée 2018
Life Eval.	5.992	6.105	5.835	5.895
GDP (log)	7.64	7.62	10.31	10.47
Freedom	54	44	84	84
Suicide	4.72	5.27	28.23	28.28

Tableau 10 — Nicaragua vs Corée du Sud (2015 et 2018).

Le paradoxe observé en 2018 se confirme en 2015 : le Nicaragua (PIB 4× plus faible, liberté plus basse) affiche un bonheur **supérieur** à la Corée du Sud sur les deux années. Le taux de suicide de la

Corée reste à un niveau alarmant (~28) contre ~5 pour le Nicaragua. Ce résultat n'est donc pas un accident statistique de 2018 : il s'agit d'un **phénomène durable** qui illustre concrètement que la richesse matérielle ne garantit pas le bien-être perçu.

6.5 Synthèse de l'analyse comparative

La réplication de l'ensemble du pipeline sur 2015 permet de tirer des conclusions robustes :

- **Les structures de corrélation sont stables** : les relations entre variables ne sont pas conjoncturelles mais reflètent des mécanismes profonds et durables du bonheur à l'échelle mondiale.
- **La hiérarchie des modèles est conservée** : le Random Forest à 11 variables domine systématiquement, le Gradient Boosting tend à l'overfitting, et le modèle Internet reste une alternative sociologiquement riche.
- **La classe intermédiaire résiste à la classification** : ce n'est pas un problème de données mais une réalité intrinsèque du bonheur des pays à développement moyen.
- **Le clustering non supervisé reproduit le classement du bonheur** de manière fiable et indépendante de l'année, validant la pertinence des indicateurs choisis.
- **Le paradoxe richesse/bonheur persiste** : le cas Nicaragua vs Corée du Sud confirme que des facteurs non économiques (santé mentale, lien communautaire) jouent un rôle déterminant dans le bien-être perçu.

7. Conclusion Générale

Ce projet avait pour ambition de modéliser le bonheur déclaré des pays à partir d'indicateurs objectifs, en allant au-delà des dimensions classiques du World Happiness Report. L'analyse conduite sur deux années (2015 et 2018) permet d'établir des conclusions qui dépassent le cadre d'une année particulière.

Sur le plan de la **modélisation**, le Random Forest à 11 variables offre systématiquement les meilleures performances (R^2 Test = 0.72 en 2015, 0.81 en 2018), suivi par la régression linéaire qui reste interprétable mais sous-exploite les variables secondaires. Le Gradient Boosting, malgré sa puissance théorique, tend à surapprendre lorsqu'il dispose de peu de variables.

Sur le plan **sociologique**, trois résultats émergent de manière récurrente :

- **Le développement économique reste le socle du bonheur mesuré.** Quel que soit le modèle, le PIB (ou son proxy Internet) domine la prédiction. Cependant, ce résultat ne signifie pas que l'argent « fait » le bonheur : il signifie que les conditions matérielles de base sont un prérequis nécessaire.
- **La liberté et l'environnement comptent.** Freedom_Score et PM25 conservent un poids significatif dans tous les modèles non linéaires, sur les deux années. Un pays pollué et peu libre sera moins heureux, même s'il est riche.
- **Les pays intermédiaires échappent à la modélisation.** Ni la régression, ni la classification, ni le clustering ne parviennent à bien traiter la zone 4.5–6.0 du bonheur. Cela suggère que des facteurs qualitatifs — culture, solidarité communautaire, rapport au temps, spiritualité — jouent un rôle déterminant dans cette zone où les contraintes matérielles sont partiellement levées.

L'introduction de variables originales (taux de suicide, pollution PM2.5, accès à la mer, solde migratoire, inégalités de genre) a permis de réduire une partie du « résidu » inexpliqué du WHR. Le cas Nicaragua vs Corée du Sud, **confirmé sur les deux années**, illustre concrètement que le PIB ne suffit pas : un pays plus pauvre mais avec moins de pression sociale peut afficher un bonheur supérieur.

Limites de l'étude. Avec seulement 156 pays, le jeu de test (20 %) ne contient que 31-32 pays. Cette taille réduite a deux conséquences importantes :

1. Les métriques de performance (R^2 , précision, F1) sont sensibles à la composition du split : un pays atypique dans le jeu de test peut faire varier significativement les scores. La cross-validation (5-fold) sur le train permet d'obtenir une estimation plus robuste, mais chaque fold ne contient alors que ~25 pays.
2. En classification, avec 3 classes et 32 pays en test, certaines classes ne contiennent que 7 à 17 pays, ce qui rend les matrices de confusion et les scores par classe particulièrement volatils.

Concernant les hyperparamètres, nous n'avons pas effectué de grid search : avec seulement ~125 observations d'entraînement, optimiser finement les hyperparamètres reviendrait à ajuster le modèle au bruit du jeu d'entraînement. Nous avons donc fixé des valeurs conservatrices. Pour le Random Forest, max_depth=5 et min_samples_leaf=5 empêchent les arbres de mémoriser des cas individuels. Pour le Gradient Boosting, un learning_rate de 0.05, une profondeur limitée à 3 et une régularisation L2 freinent l'overfitting.

Question ouverte : nos modèles montrent une corrélation entre richesse et bonheur, mais est-ce que la richesse cause le bonheur, ou est-ce l'inverse (les gens heureux sont plus productifs) ? Ou bien les deux sont-ils causés par un facteur tiers (stabilité politique, capital social...) que nous n'avons pas réussi à intégrer ? La réplication sur deux années n'a pas résolu cette question — elle a plutôt confirmé qu'il s'agit d'une **limitation fondamentale de la modélisation statistique**, qui capture des associations mais ne tranche pas la causalité. Cette question reste ouverte et constitue une piste naturelle pour de futurs travaux.

Bibliographie

- [1] Helliwell, J. F., Layard, R., Sachs, J. D., De Neve, J.-E., Aknin, L. B. & Wang, S. (Eds.). World Happiness Report 2025. University of Oxford: Wellbeing Research Centre.
- [2] Ritchie, H., Mathieu, E., Rod s-Guirao, L., Appel, C., Giattino, C., Ortiz-Ospina, E., Hasell, J., Macdonald, B., Beltekian, D. & Roser, M. Our World in Data.
- [3] Mounk, Y. (2024). The World Happiness Report Is a Sham. Persuasion.
- [4] Zhang, X. et al. (2019). PM2.5 Concentrations and Subjective Well-Being: Longitudinal Evidence from Aggregated Panel Data from Chinese Provinces. PubMed.
- [5] OpenClassrooms. D couvrez l'algorithme k-means. OpenClassrooms Cours en ligne.
- [6] DataScientest. Dendrogramme : tout sur le diagramme de clustering hi rarchique. Data Scientest.
- [7] IBM. What Is Gradient Boosting?. IBM Think.
- [8] pandas development team. Merge, join, concatenate and compare. pandas 3.0.2 documentation
- [9] pandas development team. pandas.qcut et pandas.cut. pandas documentation.